Tegar Rahmadani Firdaus

UTS_Tegar_Rahmadani_Firdaus_P36202600005.pdf

Subclass 1

3-10 November 2026

Universitas Dian Nuswantoro

Document Details

Submission ID
trn:oid:::1:3703958873

Submission Date
Nov 7, 2026, 3:13 PM GMT+7

Download Date
Nov 7, 2026, 3:16 PM GMT+7

File Name
UTS_Tegar_Rahmadani_Firdaus_P36202600005.pdf

File Size
480.4 KB

14 Pages

11,239 Words

69,357 Characters

1% Overall Similarity

The combined total of all matches, including overlapping sources, for each database.

Filtered from the Report

- Bibliography

Top Sources

1% Internet sources
1% Publications
0% Submitted works (Student Papers)

Top Sources

1% Internet sources
1% Publications
0% Submitted works (Student Papers)

Top Sources

The sources with the highest number of matches within the submission. Overlapping sources will not be displayed.

1 Internet
adoc.pub <1%

2 Publication
Pria Juli Ade Malau, Guruh Fajar Shidik, Catur Supriyanto. "Time-Scale Modificatio... <1%

3 Internet
shsu-ir.tdl.org <1%

4 Publication
Hillary Octa Fatica, Aviv Fitria Yulia, Ferly Ardhy, Fahlul Rizki. "Perbandingan Kine... <1%

5 Internet
ejournal4.unud.ac.id <1%

6 Internet
opal.latrobe.edu.au <1%

7 Internet
www.cepheid.com <1%

8 Internet
www.mdpi.com <1%

9 Internet
repository.its.ac.id <1%

SEGMENTASI PRESTASI AKADEMIK SISWA PADA TINGKAT MATA PELAJARAN MENGGUNAKAN K-MEANS++ BERBASIS STABILITAS

Tegar Rahmadani Firdaus
Fakultas Teknologi Cerdas
Universitas Dian Nuswantoro
Semarang, Indonesia
P36202600005@mhs.dinus.ac.id

Guruh Fajar Shidik
Fakultas Teknologi Cerdas
Universitas Dian Nuswantoro
Semarang, Indonesia
guruh.fajar.shidik@dsn.dinus.ac.id

Abstrak—Prestasi siswa umumnya diringkas melalui nilai agregat, meskipun siswa dengan kinerja keseluruhan yang serupa dapat menunjukkan kekuatan dan kesulitan yang berbeda pada tingkat mata pelajaran. Penelitian ini mengembangkan pipeline segmentasi pada tingkat mata pelajaran menggunakan K-Means++ pada data Penilaian Akhir Semester (PAS) dari SMA Negeri 1 Jakenan. Buku kerja yang disediakan berisi 19.401 record, 1.292 nama siswa unik, 38 label kelas, dan 30 label mata pelajaran. Setelah normalisasi label kelas, pembersihan record, pembentukan kohort yang sesuai dengan kurikulum, penyaringan cakupan mata pelajaran, penyaringan kelengkapan siswa, imputasi median khusus kohort, penghapusan fitur dengan varians nol, dan standardisasi z-score, diperoleh 1.277 siswa yang tersebar dalam lima kohort. K-Means++ dievaluasi untuk k=2–8 menggunakan 30 seed acak pada setiap konfigurasi. Koefisien Silhouette, Davies–Bouldin Index (DBI), dan Adjusted Rand Index (ARI) berpasangan digabungkan melalui seleksi multiobjektif berbasis Pareto. Solusi terpilih adalah k=2 untuk setiap kohort, dengan nilai rata-rata Silhouette sebesar 0.2299–0.3165, nilai DBI sebesar 1.1787 - 1.5038, dan nilai rata-rata ARI berpasangan sebesar 0.9498 - 1.0000. Benchmark tambahan menerapkan K-Means dengan inisialisasi acak, DBSCAN, BIRCH, Gaussian Mixture Models (GMM), dan Mean Shift pada matriks kohort yang telah distandardisasi. DBSCAN menghasilkan nilai Silhouette yang tinggi pada beberapa konfigurasi, tetapi mengecualikan 72.5%–95.1% observasi sebagai noise, sehingga membatasi keterbandingan langsung. Hasil menunjukkan partisi pada tingkat inisialisasi yang dapat diulang dengan pemisahan sedang, bukan kategori siswa yang definitif atau berlaku secara universal. Profil yang dihasilkan dapat mendukung pemantauan akademik eksploratif pada tingkat mata pelajaran apabila diinterpretasikan bersama penilaian guru dan bukti kontekstual.

Kata Kunci—data mining pendidikan, prestasi akademik, segmentasi siswa, nilai tingkat mata pelajaran, K-Means++, stabilitas clustering, koefisien Silhouette, Adjusted Rand Index.

I. PENDAHULUAN

Institusi pendidikan secara rutin mengumpulkan catatan penilaian yang dapat dianalisis untuk memahami hasil belajar dan mengidentifikasi pola yang tidak terlihat dalam pelaporan rutin. Educational Data Mining (EDM) menerapkan teknik komputasi dan statistik pada data pendidikan untuk memperoleh informasi yang dapat mendukung peserta didik, pendidik, dan institusi. Dutt et al. [1] menjelaskan EDM sebagai bidang penelitian yang berkembang dan mengkaji penggunaan clustering serta metode data mining lainnya dalam lingkungan pendidikan. Metode tersebut sangat relevan ketika data pendidikan memiliki banyak dimensi dan tujuan analisis bersifat eksploratif, bukan untuk memprediksi label yang telah ditentukan sebelumnya.

Prestasi akademik bersifat multidimensional. Seorang siswa dapat memperoleh nilai keseluruhan yang sedang, tetapi memiliki kinerja yang relatif baik pada beberapa mata pelajaran dan mengalami kesulitan pada mata pelajaran lainnya. Jika analisis hanya menggunakan rata-rata atau median keseluruhan, perbedaan antarbidang mata pelajaran akan terkompresi menjadi satu nilai. Chen et al. [2] juga menekankan bahwa penggunaan nilai keseluruhan dapat mengabaikan karakteristik masing-masing mata pelajaran. Fitur pada tingkat mata pelajaran dapat mempertahankan lebih banyak informasi untuk pemrofilan, selama analisis memperhatikan perbedaan kurikulum dan ketersediaan mata pelajaran.

Penelitian EDM sebelumnya telah mengkaji prestasi akademik melalui berbagai perspektif analitis. Rahman et al. [3] menggabungkan indikator praktik pemrograman dan nilai akademik menggunakan clustering dan analisis asosiasi. Alhazmi dan Sheneamer [4] mengkaji clustering dan klasifikasi untuk analisis kinerja awal pada pendidikan tinggi, sedangkan Qin et al. [5] mengembangkan model peringatan dini yang mengintegrasikan unsur subjektif dan objektif. Vives et al. [6] mengkaji prediksi berbasis urutan menggunakan jaringan LSTM. Penelitian-penelitian tersebut menunjukkan luasnya analisis akademik berbasis data, tetapi tujuan prediktifnya berbeda dari segmentasi deskriptif tanpa supervisi yang dikaji dalam penelitian ini.

Clustering berguna ketika tujuan penelitian adalah menemukan kelompok tanpa label kelas yang telah ditentukan sebelumnya. Namun, partisi yang dihasilkan bergantung pada representasi fitur, preprocessing, geometri jarak, konfigurasi algoritma, dan inisialisasi. Pecuchova dan Drlik [7] menunjukkan penggunaan clustering pada jejak digital siswa dan menyoroti nilai analisis berbasis waktu dan konten. Chen et al. [8] menggunakan repositori berversi untuk memperoleh indikator perilaku belajar. Penelitian tersebut mendorong pertimbangan yang cermat terhadap sumber data: penelitian ini menggunakan nilai ujian, bukan jejak perilaku, sehingga menggambarkan profil hasil akademik, bukan keterlibatan atau proses belajar.

K-Means merupakan metode partisi yang banyak digunakan, tetapi solusinya dapat berubah bergantung pada inisialisasi

6

Colorful Harris dan de Amorim [9] memberikan perbandingan empiris algoritma inisialisasi K-Means pada dataset sintetis dan dunia nyata, yang menunjukkan bahwa pilihan inisialisasi merupakan dimensi eksperimen yang penting. Dalam data mining pendidikan, Andre et al. [10] membandingkan K-Means, DBSCAN, BIRCH, Gaussian Mixture Models, dan Mean Shift untuk clustering data topik skripsi mahasiswa. Mutka et al. [11] selanjutnya menunjukkan bagaimana EDM dapat mendukung analisis retensi siswa melalui indikator validasi pembelajaran yang terperinci. Penelitian-penelitian tersebut memberikan konteks metodologis untuk pengulangan K-Means++ dan perbandingan tambahan dengan keluarga algoritma pembanding dalam paper ini.

Penelitian ini menganalisis nilai mata pelajaran PAS dari SMA Negeri 1 Jakenan dan menjawab tiga pertanyaan penelitian: (1) Bagaimana record PAS berformat long dapat diubah menjadi matriks siswa-per-mata-pelajaran yang kompatibel dengan kurikulum? (2) Berapa jumlah cluster yang memberikan keseimbangan terbaik yang teramati antara kualitas cluster internal dan keterulangan inisialisasi untuk setiap kohort? (3) Profil nilai tingkat mata pelajaran apa yang menjadi karakteristik partisi terpilih? Kontribusi penelitian ini adalah alur kerja preprocessing dan segmentasi yang dapat direproduksi, evaluasi K-Means++ berulang pada 30 seed, seleksi berbasis Pareto menggunakan tiga kriteria internal, serta perbandingan eksploratif yang transparan dengan lima keluarga algoritma pembanding. Penelitian ini tidak mengklaim dapat memprediksi kinerja masa depan atau menetapkan penjelasan kausal atas prestasi siswa.

II. PENELITIAN TERKAIT

EDM menyediakan kerangka untuk menganalisis data yang dihasilkan dalam lingkungan pendidikan. Tinjauan sistematis oleh Dutt et al. [1] membahas perkembangan EDM dan penerapan clustering pada dataset pendidikan. Clustering dapat mendukung identifikasi kelompok dengan karakteristik serupa, tetapi kegunaannya bergantung pada apakah atribut yang dipilih merepresentasikan pertanyaan pendidikan yang diteliti. Dalam penelitian ini, atribut yang digunakan adalah nilai mata pelajaran PAS individual, bukan karakteristik demografis, kehadiran, atau aktivitas daring.

Beberapa penelitian menggunakan hasil akademik sebagai masukan untuk model prediktif atau deskriptif. Rahman et al. [3] meneliti keterampilan pemrograman praktis bersama prestasi akademik, yang menunjukkan nilai penggabungan berbagai sumber bukti. Alhazmi dan Sheneamer [4] menganalisis indikator akademik awal dan membandingkan teknik clustering dan klasifikasi. Qin et al. [5] mengintegrasikan faktor subjektif dan objektif dalam model peringatan dini kinerja. Vives et al. [6] menerapkan model berbasis LSTM pada informasi penilaian berurutan dalam dasar-dasar pemrograman. Pendekatan tersebut relevan dengan tujuan yang lebih luas dalam pemantauan akademik, tetapi memerlukan struktur data dan protokol evaluasi yang berbeda dari clustering tanpa supervisi terhadap nilai mata pelajaran dalam satu semester.

Pemrofilan siswa juga telah dipelajari menggunakan jejak pendidikan non-nilai. Pecuchova dan Drlik [7] meneliti jejak digital Moodle dan membandingkan pendekatan clustering untuk mengidentifikasi profil aktivitas siswa yang berkaitan dengan risiko putus sekolah. Chen et al. [8] menambang repositori version-control untuk memperoleh indikator perilaku belajar dari tugas pemrograman. Mutka et al. [11] menggunakan indikator proses pemrograman yang terperinci untuk prediksi hasil awal. Penelitian tersebut menunjukkan bahwa pemantauan akademik dapat memperoleh manfaat dari data yang lebih kaya, sekaligus memperjelas cakupan penelitian ini: workbook PAS yang tersedia hanya berisi nilai mata pelajaran, sehingga analisis tidak dapat menyimpulkan kehadiran, usaha, motivasi, atau perilaku belajar temporal.

Pemilihan dan validasi algoritma merupakan bagian utama dalam clustering. Harris dan de Amorim [9] membandingkan 17 algoritma inisialisasi dan menunjukkan bahwa kinerja inisialisasi bergantung pada karakteristik data. Andre et al. [10] membandingkan beberapa keluarga clustering dalam konteks EDM dan memberikan preseden praktis untuk mengevaluasi pendekatan partisi, berbasis kepadatan, hierarkis/CF-tree, dan probabilistik pada data pendidikan. Penelitian ini mengadopsi K-Means++ sebagai metode utama karena rancangan penelitian secara eksplisit mengevaluasi keterulangan inisialisasinya, serta menggunakan keluarga algoritma pembanding yang dibahas oleh Andre et al. sebagai benchmark tambahan. Benchmark dilakukan pada matriks PAS saat ini dan tidak mereplikasi dataset maupun pengaturan eksperimen Andre et al.

Research gap yang dibahas di sini lebih sempit daripada klaim umum bahwa clustering masih kurang digunakan dalam pendidikan. Penelitian yang ada telah menunjukkan nilai EDM, pemrofilan siswa, dan perbandingan clustering, tetapi kumpulan penelitian yang digunakan belum menyediakan analisis langsung terhadap profil PAS pada tingkat mata pelajaran dalam kohort yang kompatibel dengan kurikulum di SMA Negeri 1 Jakenan menggunakan inisialisasi K-Means++ berulang dan aturan seleksi gabungan kualitas internal/keterulangan. Penelitian ini menjawab gap metodologis dan kontekstual tersebut secara spesifik. Penelitian ini tidak mengklaim bahwa dua kelompok yang dihasilkan merupakan tipe siswa yang muncul secara alami atau bahwa metode ini mengungguli seluruh alternatif secara umum.

III. DATASET DAN AUDIT DATA

Dataset merupakan workbook PAS Semester 1 SMA Negeri 1 Jakenan. Sheet1 berisi 19.401 record berformat long dan delapan field: ABSEN, KELAS, NAMA, NILAI, MATA PELAJARAN, GURU PENGAMPU, NOMOR, dan HARI KE. Audit awal mengidentifikasi 1.292 nama siswa unik, 38 label kelas mentah, dan 30 label mata pelajaran. Workbook juga memiliki sheet kedua dengan 21 baris entri tambahan; workflow Colab yang dijalankan menggunakan Sheet1 sebagai masukan analisis.

Audit konversi numerik mengidentifikasi 243 entri NILAI nonnumerik: 221 entri bertanda “Belum Ikut” dan 22 entri bertanda “Kristen”. Penanda “Belum Ikut” merepresentasikan penilaian yang belum selesai atau tidak tersedia dan diperlakukan sebagai nilai hilang, bukan dikonversi menjadi nol. Sebanyak 22 penanda “Kristen” muncul pada pasangan siswa–mata pelajaran yang berulang dan memiliki pasangan nilai numerik. Preprocessing memprioritaskan nilai numerik dan mempertahankan satu record untuk setiap kunci siswa–mata pelajaran yang telah dinormalisasi. Keputusan pembersihan data ini perlu dikonfirmasi kepada pemilik data sekolah sebelum penerapan operasional.

Label kelas “XII - IPA n” dinormalisasi menjadi “XII - MIPA n” sebelum penetapan kohort. Kunci siswa yang digunakan untuk linkage adalah gabungan kelas yang telah

duplikasi dan nama siswa, kunci ini tidak dimasukkan sebagai fitur clustering. Tabel long yang telah dibersihkan berisi 19.379 record. Selanjutnya dibentuk lima kohort yang kompatibel dengan kurikulum: Kelas X, Kelas XI 01–04, Kelas XI 05–12, Kelas XII MIPA, dan Kelas XII IPS. Pengelompokan ini mengikuti pola penawaran mata pelajaran yang diamati pada workbook dan menghindari perlakuan terhadap mata pelajaran yang tidak ditawarkan kepada suatu kohort sebagai nilai nol.

TABEL I. AUDIT DATA MENTAH

Item Audit	Nilai yang Diamati
Record PAS pada Sheet1	19,401
Nama siswa unik	1,292
Label kelas mentah / label mata pelajaran	38 / 30
Entri NILAI nonnumerik	243 (221 “Belum Ikut”; 22 “Kristen”)
Pasangan siswa–mata pelajaran berulang	22 pairs (44 rows)
Record setelah pembersihan	19,379

IV. METODOLOGI

A. Konstruksi Fitur Tingkat Mata Pelajaran

Dalam setiap kohort, data long diubah melalui pivot menjadi matriks X yang barisnya merepresentasikan siswa dan kolomnya merepresentasikan mata pelajaran. Sel X_{ij} berisi nilai PAS siswa i pada mata pelajaran j. Kunci siswa hanya digunakan sebagai indeks baris. Kunci tersebut dikeluarkan dari ruang fitur numerik agar identitas atau kode kelas tidak memengaruhi perhitungan jarak.

Cakupan mata pelajaran dihitung sebagai proporsi siswa dalam suatu kohort yang memiliki nilai numerik untuk mata pelajaran tersebut. Eksperimen utama mempertahankan suatu mata pelajaran ketika cakupannya minimal 80%. Setelah fitur mata pelajaran dipilih, seorang siswa dipertahankan ketika setidaknya 80% fitur tersebut teramati. Kedua ambang tersebut menangani dua sumber ketidaklengkapan yang berbeda: sparsity pada tingkat mata pelajaran dan missingness pada tingkat siswa. Matriks yang dipertahankan dibangun secara independen untuk setiap kohort.

B. Penanganan Nilai Hilang dan Standardisasi

Sel yang masih hilang diimputasi menggunakan median nilai mata pelajaran yang bersangkutan dalam kohort yang sama. Imputasi khusus kohort menghindari peminjaman distribusi nilai antarjenjang kelas atau kelompok akademik. Fitur dengan varians nol setelah imputasi dihapus karena tidak dapat membedakan observasi dalam kohort. Fitur yang tersisa ditransformasi menggunakan standardisasi z-score yang diimplementasikan dengan StandardScaler. Standardisasi memberikan skala yang sebanding untuk setiap fitur mata pelajaran dalam clustering berbasis jarak Euclidean; hal ini tidak berarti bahwa semua mata pelajaran memiliki kepentingan pendidikan yang sama.

Analisis sensitivitas mengulangi pemilihan fitur mata pelajaran menggunakan ambang cakupan 70%, 80%, dan 90%, dengan tetap mempertahankan ambang kelengkapan siswa sebesar 80%. Analisis ini memeriksa apakah jumlah siswa dan fitur berubah di bawah aturan cakupan mata pelajaran yang berbeda. Analisis ini bukan merupakan analisis stabilitas berbasis perturbasi secara penuh.

C. Eksperimen K-Means++

K-Means mempartisi n observasi menjadi k cluster dengan menetapkan setiap observasi ke centroid terdekat dan memperbarui centroid secara iteratif. Tujuannya adalah meminimalkan jumlah kuadrat jarak Euclidean dalam cluster. K-Means++ menggunakan seeding yang mempertimbangkan jarak: setelah memilih centroid awal, centroid berikutnya diambil dengan probabilitas yang proporsional terhadap kuadrat jarak dari centroid terpilih terdekat. Strategi inisialisasi ini relevan karena K-Means dapat konvergen ke solusi lokal yang berbeda bergantung pada pusat awalnya, sebagaimana dibahas secara empiris oleh Harris dan de Amorim [9].

Untuk setiap kohort, eksperimen mengevaluasi $k \in \{2,3,4,5,6,7,8\}$. Setiap kandidat menggunakan 30 seed acak (0–29), init=“k-means++”, n_init=1, dan max_iter=500. Pengaturan n_init=1 membuat setiap seed merepresentasikan satu inisialisasi eksplisit sehingga memungkinkan perbandingan berpasangan antarpartisi yang dihasilkan. Referensi k tetap menggunakan inisialisasi acak konvensional dengan k=3, n_init=10, dan random_state=42. Konfigurasi ini merupakan baseline pada matriks kohort yang sama, bukan perbandingan dengan dataset yang berbeda.

D. Validasi Internal dan Keterulangan Inisialisasi

Koefisien Silhouette mengukur kohesi relatif dan pemisahan suatu partisi. Untuk setiap observasi, a(i) adalah jarak rata-rata terhadap observasi dalam cluster yang sama dan b(i) adalah jarak rata-rata minimum terhadap cluster lain; koefisiennya adalah $(b(i)-a(i))/\max(a(i),b(i))$. Nilai yang lebih tinggi menunjukkan pemisahan yang lebih kuat, nilai mendekati nol menunjukkan batas yang saling tumpang tindih, dan nilai negatif menunjukkan bahwa suatu observasi mungkin lebih dekat dengan cluster lain.

Davies–Bouldin Index (DBI) merangkum rasio dispersi dalam cluster terhadap pemisahan antarcentroid. Nilai yang lebih rendah lebih disukai. Silhouette dan DBI memberikan pandangan internal yang saling melengkapi, tetapi keduanya bukan ukuran akurasi klasifikasi atau validitas pendidikan. Karena dataset tidak memiliki label cluster ground-truth, accuracy, precision, recall, dan F1-score tidak dapat diterapkan.

Adjusted Rand Index (ARI) membandingkan dua partisi dengan mengukur kesesuaian penetapan pasangan yang disesuaikan terhadap peluang. Untuk setiap k, ARI dihitung untuk seluruh pasangan tak berurutan dari 30 partisi yang spesifik terhadap seed. Terdapat $30\times29/2=435$ perbandingan berpasangan untuk setiap kohort dan k. Rata-rata ARI berpasangan menunjukkan keterulangan inisialisasi pada observasi tetap yang sama. Nilai tersebut tidak menetapkan stabilitas ketika dilakukan resampling siswa, perubahan semester, atau replikasi eksternal.

E. Seleksi Berbasis Pareto

k terpilih ditentukan menggunakan tiga tujuan: memaksimalkan rata-rata Silhouette, memaksimalkan rata-rata ARI berpasangan, dan meminimalkan rata-rata DBI. Suatu kandidat dikatakan didominasi Pareto ketika kandidat lain setidaknya sama baiknya pada ketiga tujuan dan secara ketat lebih baik pada setidaknya satu tujuan. Kandidat yang tidak didominasi membentuk himpunan Pareto. Jika beberapa kandidat tetap tersisa, aturan pemecah seri yang telah ditetapkan memilih rata-rata Silhouette tertinggi, kemudian rata-rata ARI tertinggi, dan selanjutnya rata-rata

DBI terendah. Prosedur ini membuat aturan seleksi eksplisit dan menghindari ketergantungan pada satu metrik internal.

F. Benchmark Tambahan Algoritma Pembanding

Notebook Colab juga mengevaluasi keluarga algoritma yang dibahas oleh Andre et al. [10]: K-Means dengan inisialisasi acak, DBSCAN, BIRCH, Gaussian Mixture Model (GMM), dan Mean Shift. Semua metode menggunakan matriks kohort yang sama dan telah distandardisasi. Random K-Means menguji k=2–8 dengan n_init=10 dan random_state=42. DBSCAN menguji eps∈{0.5,0.7,0.9,1.1,1.3,1.5,1.8,2.0} dan min_samples∈{5,10}. BIRCH menguji 2–8 cluster dengan threshold=0.5. GMM menguji 2–8 komponen dengan full covariance, reg_covar=10^{-5}, n_init=3, dan random_state=42. Mean Shift mengestimasi bandwidth menggunakan quantile=0.2 dan maksimal 500 sampel.

Untuk setiap algoritma dan kohort, konfigurasi kandidat yang valid diurutkan berdasarkan Silhouette, dengan DBI yang lebih rendah digunakan sebagai kriteria pengurutan sekunder. Partisi dianggap tidak valid ketika kurang dari dua cluster tersisa atau ketika setiap observasi yang dievaluasi membentuk cluster sendiri. Untuk DBSCAN, observasi noise (label −1) dikeluarkan dari perhitungan Silhouette dan DBI, sedangkan rasio noise dilaporkan secara terpisah. Penanganan ini penting: Silhouette yang tinggi pada subset kecil yang dipertahankan tidak dapat diinterpretasikan sebagai segmentasi yang lebih baik secara keseluruhan tanpa mempertimbangkan proporsi observasi yang dikecualikan. Karena pemilihan konfigurasi dan pelaporan metrik menggunakan matriks yang sama, benchmark ini bersifat eksploratif dan dapat bersifat optimistis.

V. HASIL EKSPERIMEN

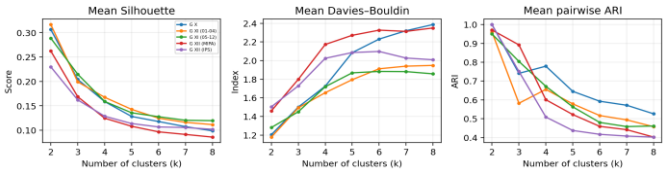
Pipeline utama dengan cakupan 80% mempertahankan 1.277 siswa dalam lima kohort. Matriks kohort berisi 10–16 fitur mata pelajaran. Eksperimen utama menyelesaikan 35 konfigurasi kohort-k (lima kohort × tujuh nilai k), dengan 30 seed dan 435 perbandingan ARI berpasangan untuk setiap konfigurasi.

TABEL II. RINGKASAN MATRIKS FITUR KOHORT

Kohort	Siswa	Mata Pelajaran	Sel Diimputasi
Kelas X	426	16	25
Kelas XI (01–04)	142	13	3
Kelas XI (05–12)	284	10	11
Kelas XII MIPA	283	15	22
Kelas XII IPS	142	14	25
Total	1,277	—	86

TABEL III. HASIL K-MEANS++ TERPILIH (k=2)

Kohort	N	Silhouette	DBI	Rata-rata ARI
Kelas X	426	0.3064	1.2047	1.0000
Kelas XI (01–04)	142	0.3165	1.1787	0.9600
Kelas XI (05–12)	284	0.2887	1.2813	0.9498
Kelas XII MIPA	283	0.2624	1.4601	0.9711
Kelas XII IPS	142	0.2299	1.5038	1.0000



Gbr. 1. Rata-rata metrik validasi internal dan keterulangan inisialisasi untuk k=2–8.

Pada kelima kohort, k=2 merupakan satu-satunya kandidat yang tidak didominasi berdasarkan prosedur Pareto yang ditetapkan. Nilai rata-rata Silhouette terpilih berkisar antara 0.2299 hingga 0.3165. DBI terendah adalah 1.1787 untuk Kelas XI 01–04, sedangkan tertinggi adalah 1.5038 untuk Kelas XII IPS. Rata-rata ARI berpasangan berkisar antara 0.9498 hingga 1.0000. Nilai-nilai tersebut menunjukkan bahwa inisialisasi K-Means++ yang diulang menghasilkan partisi yang serupa pada matriks tetap, sedangkan nilai Silhouette yang sedang menunjukkan bahwa kelompok tidak terpisah secara tajam.

Kelas X dan Kelas XII IPS menghasilkan rata-rata ARI berpasangan sebesar 1.0000, yang menunjukkan partisi identik pada 30 inisialisasi untuk k=2. Kelas XI 01–04, Kelas XI 05–12, dan Kelas XII MIPA juga menunjukkan keterulangan yang tinggi, dengan nilai rata-rata ARI masing-masing 0.9600, 0.9498, dan 0.9711. Simpangan baku untuk ketiga kohort tersebut adalah 0.0416, 0.0469, dan 0.0266. Hasil ini hanya berkaitan dengan sensitivitas terhadap inisialisasi dan tidak boleh digeneralisasikan ke sampel siswa yang berbeda.

TABEL IV. REFERENSI K-MEANS DENGAN INISIALISASI ACAK (k=3)

Kohort	N	Silhouette	DBI
Kelas X	426	0.2002	1.5269
Kelas XI (01-04)	142	0.1969	1.5329
Kelas XI (05-12)	284	0.2191	1.4224
Kelas XII (MIPA)	283	0.1636	1.8279
Kelas XII (IPS)	142	0.1623	1.7279

Untuk setiap kohort, solusi K-Means++ terpilih pada k=2 memiliki Silhouette lebih tinggi dan DBI lebih rendah dibandingkan referensi K-Means dengan inisialisasi acak pada k=3. Ini merupakan perbandingan antara dua konfigurasi pada matriks fitur yang sama, bukan bukti bahwa K-Means++ secara universal lebih unggul: jumlah cluster berbeda dan baseline menggunakan beberapa inisialisasi internal (n_init=10).

TABEL V. KEANGGOTAAN CLUSTER DARI SOLUSI TERPILIH

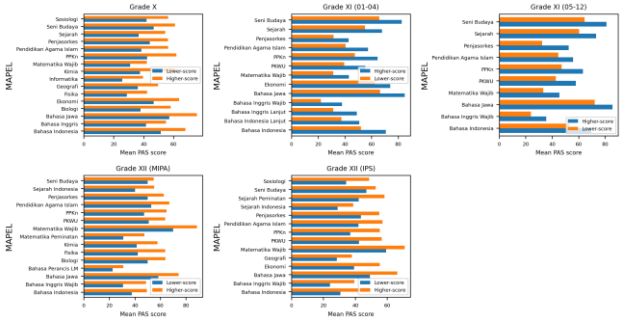
Kohort	Skor lebih rendah	Skor lebih tinggi
Kelas X	201 (47.2%)	225 (52.8%)
Kelas XI (01-04)	63 (44.4%)	79 (55.6%)
Kelas XI (05-12)	99 (34.9%)	185 (65.1%)
Kelas XII (MIPA)	107 (37.8%)	176 (62.2%)
Kelas XII (IPS)	75 (52.8%)	67 (47.2%)

Partisi terpilih dideskripsikan sebagai profil skor lebih rendah dan skor lebih tinggi berdasarkan rata-rata centroid mata pelajaran pada skala asli dalam setiap kohort. Label tersebut bersifat relatif, bukan kategori prestasi yang ditetapkan sekolah. Proporsinya bervariasi antar-kohort: Kelas XI 05–12 memiliki proporsi profil skor lebih tinggi

terbesar (65.1%), sedangkan Kelas XII IPS memiliki proporsi profil skor lebih rendah yang sedikit lebih besar (52.8%).

TABEL VI. TIGA SELISIH CENTROID MATA PELAJARAN TERBESAR PER KOHORT

Kohort	Mata Pelajaran	Lebih Rendah	Lebih Tinggi	Selisih
Kelas X	Kimia	37.5	61.2	23.7
Kelas X	Biologi	37.9	58.0	20.1
Kelas X	PPKn	42.3	61.8	19.4
Kelas XI (01-04)	Bahasa Indonesia	52.0	70.7	18.7
Kelas XI (01-04)	Bahasa Jawa	66.3	84.8	18.5
Kelas XI (01-04)	Bahasa Inggris Lanjut	31.2	48.8	17.6
Kelas XI (05-12)	Penjasorkes	32.3	52.3	20.0
Kelas XI (05-12)	Seni Budaya	64.5	81.0	16.5
Kelas XI (05-12)	Bahasa Indonesia	53.0	69.5	16.5
Kelas XII (MIPA)	Fisika	42.2	63.7	21.5
Kelas XII (MIPA)	Matematika Wajib	70.0	88.5	18.6
Kelas XII (MIPA)	Bahasa Inggris Wajib	30.7	48.7	18.0
Kelas XII (IPS)	PPKn	36.8	55.3	18.5
Kelas XII (IPS)	Bahasa Jawa	49.2	66.3	17.1
Kelas XII (IPS)	Ekonomi	39.1	55.3	16.2



Gbr. 2. Centroid mata pelajaran pada skala asli untuk profil skor lebih rendah dan skor lebih tinggi.

A. Sensitivitas Ambang Cakupan Mata Pelajaran

TABEL VII. SENSITIVITAS TERHADAP AMBANG CAKUPAN MATA PELAJARAN

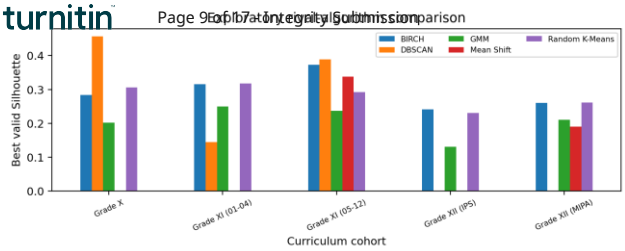
Ambang	Kohort	Siswa	Fitur
70%	Kelas X	426	16
70%	Kelas XI (01-04)	142	13
70%	Kelas XI (05-12)	284	10
70%	Kelas XII (MIPA)	283	15
70%	Kelas XII (IPS)	142	15
80%	Kelas X	426	16
80%	Kelas XI (01-04)	142	13
80%	Kelas XI (05-12)	284	10
80%	Kelas XII (MIPA)	283	15
80%	Kelas XII (IPS)	142	14
90%	Kelas X	426	16
90%	Kelas XI (01-04)	142	13
90%	Kelas XI (05-12)	284	10
90%	Kelas XII (MIPA)	283	15
90%	Kelas XII (IPS)	142	14

Jumlah siswa tetap tidak berubah pada ketiga ambang. Jumlah fitur juga tetap tidak berubah untuk empat kohort. Kelas XII IPS mempertahankan 15 fitur pada cakupan 70% dan 14 fitur pada cakupan 80% serta 90%. Dengan demikian, ambang utama 80% memiliki pengaruh terbatas terhadap jumlah fitur yang dipertahankan pada sebagian besar kohort, sedangkan himpunan fitur Kelas XII IPS agak sensitif terhadap ambang tersebut.

B. Perbandingan Algoritma Pembanding

TABEL VIII. KONFIGURASI ALGORITMA PEMBANDING VALID TERBAIK PER KOHORT

Kohort	Metode	Sil.	DBI	Cluster	Noise
Kelas X	Random K-Means	0.306	1.205	2	0.0%
Kelas X	DBSCAN	0.456	0.770	3	91.3%
Kelas X	BIRCH	0.283	1.241	2	0.0%
Kelas X	GMM	0.201	1.577	2	0.0%
Kelas X	Mean Shift	—	—	—	—
Kelas XI (01-04)	Random K-Means	0.317	1.176	2	0.0%
Kelas XI (01-04)	DBSCAN	0.145	1.679	5	72.5%
Kelas XI (01-04)	BIRCH	0.316	1.181	2	0.0%
Kelas XI (01-04)	GMM	0.250	1.349	2	0.0%
Kelas XI (01-04)	Mean Shift	—	—	—	—
Kelas XI (05-12)	Random K-Means	0.292	1.273	2	0.0%
Kelas XI (05-12)	DBSCAN	0.389	0.939	2	95.1%
Kelas XI (05-12)	BIRCH	0.373	0.988	2	0.0%
Kelas XI (05-12)	GMM	0.237	1.440	2	0.0%
Kelas XI (05-12)	Mean Shift	0.338	1.235	3	0.0%
Kelas XII (MIPA)	Random K-Means	0.261	1.463	2	0.0%
Kelas XII (MIPA)	DBSCAN	—	—	—	—
Kelas XII (MIPA)	BIRCH	0.260	1.472	2	0.0%
Kelas XII (MIPA)	GMM	0.211	1.697	2	0.0%
Kelas XII (MIPA)	Mean Shift	0.190	1.178	3	0.0%
Kelas XII (IPS)	Random K-Means	0.230	1.504	2	0.0%
Kelas XII (IPS)	DBSCAN	—	—	—	—
Kelas XII (IPS)	BIRCH	0.241	1.299	2	0.0%
Kelas XII (IPS)	GMM	0.131	2.054	2	0.0%
Kelas XII (IPS)	Mean Shift	—	—	—	—



Gbr. 3. Silhouette valid terbaik untuk metode pembanding; nilai DBSCAN hanya didasarkan pada observasi non-noise.

Random K-Means dan BIRCH menghasilkan kandidat valid untuk kelima kohort. GMM juga menghasilkan kandidat valid untuk seluruh kohort, sedangkan Mean Shift hanya menghasilkan partisi valid untuk Kelas XI 05–12 dan Kelas XII MIPA. DBSCAN menghasilkan kandidat valid pada tiga kohort; tidak ditemukan kandidat valid untuk Kelas XII MIPA dan Kelas XII IPS pada grid parameter yang diuji.

Silhouette terpilih tertinggi DBSCAN adalah 0.4564 pada Kelas X, tetapi hanya mengevaluasi 37 dari 426 siswa dan mengklasifikasikan 91.3% sebagai noise. Pada Kelas XI 01–04, kandidat DBSCAN terpilih mengevaluasi 39 dari 142 siswa dan mengecualikan 72.5% sebagai noise. Pada Kelas XI 05–12, metode ini mengevaluasi 14 dari 284 siswa dan mengecualikan 95.1% sebagai noise. Tingkat pengecualian yang besar ini berarti nilai Silhouette DBSCAN tidak dapat dibandingkan langsung dengan metode yang menetapkan seluruh siswa ke dalam cluster. Hasil tersebut dilaporkan untuk menunjukkan keterbatasan ini, bukan untuk menyatakan keunggulan DBSCAN.

Pada metode yang mencakup seluruh kohort, BIRCH kompetitif pada beberapa kohort. Untuk Kelas XI 05–12, BIRCH mencapai Silhouette 0.3733 dan DBI 0.9883, lebih tinggi daripada Silhouette K-Means++ terpilih pada kohort tersebut. Untuk Kelas XI 01–04, Random K-Means mencapai 0.3174, mendekati K-Means++ sebesar 0.3165. Perbandingan eksploratif ini menunjukkan bahwa kinerja algoritma bervariasi menurut kohort. Hasil tersebut tidak menetapkan pemenang universal karena pemilihan kandidat dilakukan pada data yang sama dengan data pelaporan, dan anggaran tuning berbeda antaralgoritma.

VI. PEMBAHASAN

Temuan utama adalah bahwa matriks PAS tingkat mata pelajaran dapat dibangun untuk lima kohort yang kompatibel dengan kurikulum dan menghasilkan partisi dua cluster yang dapat diulang di bawah inisialisasi K-Means++ berulang. Pendekatan ini mempertahankan variasi tingkat mata pelajaran yang akan hilang jika model hanya menggunakan satu statistik agregat. Hal ini konsisten dengan kekhawatiran yang dikemukakan Chen et al. [2] bahwa nilai keseluruhan dapat mengaburkan karakteristik individual. Namun, representasi fitur yang lebih kaya tidak secara otomatis menjamin validitas pedagogis; profil harus ditinjau oleh pendidik dan diinterpretasikan dalam konteks kurikulum.

Rentang Silhouette sekitar 0.23–0.32 menunjukkan pemisahan yang sedang. Partisi yang stabil tetap dapat memiliki cluster yang saling tumpang tindih: keterulangan inisialisasi dan pemisahan geometris merupakan dua sifat yang berbeda. Nilai ARI yang tinggi menunjukkan bahwa optimizer berulang kali mencapai partisi yang serupa untuk matriks data yang sama, tetapi nilai Silhouette yang sedang menjadi peringatan agar kelompok tidak diperlakukan sebagai kelompok yang terpisah secara tajam. Perbedaan ini penting ketika menerjemahkan pengelompokan matematis menjadi narasi pendidikan.

Selisih centroid terbesar berbeda antar-kohort. Kelas X menunjukkan selisih yang menonjol pada Kimia, Biologi, dan PPKn. Kelas XI 01–04 menunjukkan selisih pada Bahasa Indonesia, Bahasa Jawa, dan Bahasa Inggris Lanjut. Kelas XI 05–12 menunjukkan selisih pada Penjasorkes, Seni Budaya, dan Bahasa Indonesia. Kelas XII MIPA menunjukkan selisih pada Fisika, Matematika Wajib, dan Bahasa Inggris Wajib. Kelas XII IPS menunjukkan selisih pada PPKn, Bahasa Jawa, dan Ekonomi. Perbedaan tersebut mengidentifikasi area tempat kedua profil paling berbeda dalam matriks nilai yang diamati; perbedaan tersebut tidak mengukur kepentingan mata pelajaran, tingkat kesulitan, efektivitas guru, atau pengaruh kausal.

Penelitian EDM menggunakan beragam sumber data, termasuk nilai, aktivitas daring, log pemrograman, dan jejak digital [3], [7], [8], [11]. Dataset penelitian ini hanya berisi hasil penilaian semester. Oleh karena itu, analisis tidak dapat menyimpulkan proses belajar, keterlibatan siswa, kehadiran, atau alasan nilai yang lebih rendah. Hasil harus diperlakukan sebagai ringkasan diagnostik awal yang dapat memandu peninjauan lebih lanjut, bukan sebagai pengganti asesmen formatif atau penilaian guru.

Benchmark algoritma pembanding juga menunjukkan mengapa konteks metrik penting. DBSCAN dapat menghasilkan Silhouette tinggi pada titik inti yang dipertahankan sambil menetapkan sebagian besar siswa sebagai noise. Pelaporan Silhouette saja akan menyembunyikan kehilangan cakupan tersebut. Selain itu, konfigurasi pembanding terbaik dipilih menggunakan matriks yang sama dengan matriks tempat metriknya dilaporkan. Hal ini menimbulkan selection optimism. Perbandingan yang lebih kuat akan menetapkan protokol tuning terpisah, menilai cakupan penetapan, mengulangi metode stokastik, dan mengevaluasi stabilitas melalui resampling. Andre et al. [10] memberikan motivasi untuk keluarga algoritma tersebut, tetapi hasil yang mereka laporkan tidak dapat dipindahkan langsung ke dataset ini.

VII. IMPLEMENTASI DAN REPRODUKTIBILITAS

Eksperimen diimplementasikan di Google Colab menggunakan Python, pandas, NumPy, Matplotlib, dan scikit-learn. Notebook mengikuti pipeline berurutan: memasang Google Drive dan memuat workbook PAS; mengaudit record mentah; menormalisasi label kelas; mengonversi nilai menjadi numerik; menyelesaikan penanda nonnumerik berpasangan; menetapkan kohort kurikulum; membangun matriks mata pelajaran; menyaring mata pelajaran dan siswa; mengimputasi nilai hilang; menghapus fitur dengan varians nol; melakukan standardisasi; menjalankan K-Means++; menghitung metrik validasi; memilih k menggunakan dominasi Pareto; memprofilkan centroid; melakukan analisis sensitivitas cakupan; menjalankan algoritma pembanding; dan mengekspor hasil agregat.

Eksperimen utama berisi 5×7×30=1.050 fitting K-Means++. Untuk setiap kohort dan k, 30 partisi yang dihasilkan membentuk 435 perbandingan ARI berpasangan. Workbook keluaran dirancang untuk memuat ringkasan audit, ringkasan matriks fitur, tabel lengkap metrik k, solusi terpilih Pareto, referensi k=3, ringkasan keanggotaan, sensitivitas cakupan, profil centroid, status algoritma pembanding, dan hasil kandidat pembanding. Nilai yang dilaporkan dalam manuskrip ini dihitung ulang dari

Cuaderno yang disediakan menggunakan preprocessing dan pengaturan estimator yang sama pada notebook Colab yang diunggah. Notebook tersebut tidak memuat output eksekusi yang tersimpan; oleh karena itu, revisi ini menjalankan ulang logika komputasinya secara independen terhadap workbook yang disediakan.

VIII. ANCAMAN TERHADAP VALIDITAS, ETIKA, DAN KETERBATASAN

Pertama, dataset merepresentasikan satu sekolah dan satu semester PAS. Temuan tidak dapat digeneralisasikan ke sekolah lain, tahun akademik lain, atau sistem penilaian lain tanpa replikasi. Kedua, pemetaan kohort diinferensikan dari label kelas dan penawaran mata pelajaran yang diamati; sekolah perlu memverifikasi bahwa lima definisi kohort tersebut secara akurat merepresentasikan struktur kurikulum. Ketiga, imputasi median sederhana dan dapat direproduksi, tetapi dapat mengurangi variasi dalam mata pelajaran pada observasi yang diimputasi. Perlakuan alternatif terhadap data hilang dapat mengubah jarak Euclidean dan penetapan cluster.

Keempat, ARI berpasangan mengevaluasi keterulangan inisialisasi pada matriks tetap. Metrik ini tidak menguji stabilitas pada tingkat sampel, persistensi temporal, atau validitas eksternal. Kelima, metrik internal mengevaluasi sifat geometris, bukan kegunaan pendidikan. Tidak tersedia label ground-truth, sehingga penelitian tidak melaporkan akurasi klasifikasi, precision, recall, atau F1-score. Keenam, perbandingan algoritma pembanding menggunakan grid parameter heuristik dan memilih konfigurasi berdasarkan Silhouette pada data yang sama; perbandingan ini bersifat eksploratif dan rentan terhadap selection optimism. DBSCAN juga memiliki cakupan penetapan yang tidak lengkap.

Catatan penilaian siswa merupakan informasi pendidikan yang sensitif. Pengidentifikasi langsung, termasuk nama dan nomor absensi, tidak boleh muncul dalam notebook, repositori, gambar, atau materi tambahan yang dipublikasikan. Kunci siswa hanya digunakan untuk linkage record dan dikeluarkan dari matriks fitur. Pelaporan publik harus tetap agregat, dan workbook asli harus dibatasi hanya untuk personel yang berwenang. Otorisasi sekolah dan persyaratan tata kelola data institusi harus dikonfirmasi sebelum publikasi. Keanggotaan cluster tidak boleh digunakan sebagai satu-satunya dasar untuk pemeringkatan, kenaikan kelas, sanksi, atau akses terhadap kesempatan pendidikan.

IX. KESIMPULAN DAN PEKERJAAN MASA DEPAN

Penelitian ini mengembangkan pipeline segmentasi siswa pada tingkat mata pelajaran untuk record PAS dari SMA Negeri 1 Jakenan. Workflow preprocessing mengubah 19.401 record mentah menjadi lima kohort yang kompatibel dengan kurikulum dan mempertahankan 1.277 siswa dengan 10–16 fitur mata pelajaran per kohort. K-Means++ dievaluasi untuk k=2–8 menggunakan 30 inisialisasi acak, dan k yang terpilih adalah 2 untuk seluruh kohort berdasarkan seleksi Pareto atas rata-rata Silhouette, ARI berpasangan, dan rata-rata DBI. Solusi terpilih mencapai nilai Silhouette 0.2299–0.3165, DBI 1.1787–1.5038, dan rata-rata ARI berpasangan 0.9498–1.0000.

Temuan mendukung keterulangan partisi terpilih terhadap inisialisasi centroid, tetapi menunjukkan pemisahan yang hanya sedang. Selisih centroid pada tingkat mata pelajaran memberikan deskripsi yang lebih rinci dibandingkan satu nilai agregat, namun tetap bersifat deskriptif dan non-kausal. Perbandingan tambahan menunjukkan bahwa BIRCH dan Random K-Means dapat kompetitif pada kohort tertentu, dan bahwa nilai Silhouette DBSCAN yang tinggi harus diinterpretasikan bersama pengecualian noise yang besar. Tidak ada algoritma yang dinyatakan unggul secara universal.

Pekerjaan masa depan perlu mengevaluasi stabilitas pada tingkat sampel melalui repeated subsampling atau bootstrap, mereplikasi analisis pada semester berikutnya, membandingkan strategi imputasi dan jarak alternatif, serta memperoleh umpan balik terstruktur dari guru mata pelajaran. Pengembangan tersebut akan menguji apakah profil tetap bertahan terhadap perturbasi data dan apakah profil tersebut memberikan informasi yang berguna untuk dukungan akademik. Output saat ini sebaiknya dipandang sebagai alat bantu keputusan eksploratif, bukan sistem asesmen siswa otomatis.

UCAPAN TERIMA KASIH

Penulis mengucapkan terima kasih kepada pihak sekolah dan penyedia data terkait yang telah menyediakan dataset PAS untuk penelitian, dengan tetap menunggu konfirmasi izin untuk mengakui institusi secara publik.

LAMPIRAN A. SINTESIS LITERATUR TERPERINCI

Untuk memperjelas hubungan antara penelitian ini dan sebelas artikel jurnal yang digunakan, literatur dapat dikelompokkan menjadi empat alur yang saling berkaitan. Alur pertama berkaitan dengan cakupan dan landasan EDM. Dutt et al. [1] meninjau data mining pendidikan sebagai bidang yang mengadaptasi teknik data mining ke lingkungan pendidikan dan menjelaskan clustering sebagai salah satu metode untuk mengidentifikasi kelompok observasi pendidikan yang serupa. Tinjauan tersebut mendukung pemilihan pendekatan eksploratif tanpa supervisi, sekaligus menekankan bahwa dataset pendidikan memiliki karakteristik kontekstual yang perlu dipertimbangkan selama preprocessing.

Alur kedua berfokus pada prestasi akademik dan analitik berorientasi hasil. Rahman et al. [3] menganalisis keterampilan pemrograman praktis bersama nilai akademik dan menunjukkan bagaimana pengelompokan tanpa supervisi dapat mengungkap profil yang mungkin berguna untuk dukungan yang terdiferensiasi. Alhazmi dan Sheneamer [4] mengkaji clustering dan klasifikasi dalam konteks analisis kinerja awal pada pendidikan tinggi. Qin et al. [5] mengembangkan model peringatan dini yang mengintegrasikan unsur subjektif dan objektif, sedangkan Vives et al. [6] mengevaluasi prediksi berbasis LSTM pada beberapa titik dalam mata kuliah pemrograman. Penelitian tersebut memiliki motivasi umum yang sama, yaitu mendukung keputusan akademik melalui data, tetapi target prediktif serta konteks pendidikan tinggi/pemrogramannya tidak setara dengan tugas segmentasi PAS sekolah menengah dalam penelitian ini.

Alur ketiga berkaitan dengan sumber data alternatif untuk memahami siswa. Pecuchova dan Drlik [7] menganalisis jejak digital Moodle dan membandingkan pendekatan clustering untuk mengidentifikasi profil aktivitas siswa yang berkaitan dengan risiko putus sekolah. Chen et al. [8] menggunakan repositori perangkat lunak berversi untuk mendeteksi perilaku belajar dalam tugas pemrograman. Mutka et al. [11] menganalisis indikator proses terperinci seperti aktivitas pengodean dan pola pengumpulan tugas untuk mendukung prediksi berorientasi retensi. Penelitian tersebut menunjukkan bahwa learning analytics dapat

interpretasikan proses, keterlibatan, dan perilaku temporal. Sebaliknya, penelitian ini hanya memiliki nilai penilaian mata pelajaran selama satu semester. Perbedaan tersebut penting karena cluster berbasis nilai tidak dapat diinterpretasikan sebagai tipe perilaku, tingkat keterlibatan, atau kelas risiko putus sekolah.

Alur keempat berkaitan dengan algoritma clustering dan perbandingan empirisnya. Harris dan de Amorim [9] menunjukkan bahwa algoritma inisialisasi dapat memengaruhi hasil K-Means pada berbagai kondisi data. Andre et al. [10] membandingkan K-Means, DBSCAN, BIRCH, Gaussian Mixture Models, dan Mean Shift dalam studi kasus EDM yang melibatkan data topik skripsi mahasiswa. Penelitian mereka sangat relevan dengan benchmark tambahan dalam paper ini. Namun, ruang fitur dan masalah pendidikan yang digunakan berbeda: representasi topik skripsi bukan vektor nilai PAS numerik. Oleh karena itu, penelitian ini menggunakan keluarga algoritma tersebut sebagai referensi desain komparatif, tetapi tidak membandingkan metrik numeriknya secara langsung dengan nilai yang dipublikasikan Andre et al.

Sebelas penelitian tersebut secara kolektif menunjukkan bahwa EDM mencakup clustering deskriptif, pemodelan prediktif, dan learning analytics berdasarkan berbagai sumber data. Kontribusi penelitian ini sengaja dibuat spesifik: menguji apakah vektor siswa-per-mata-pelajaran PAS dapat disegmentasikan dalam kohort yang kompatibel dengan kurikulum, serta apakah partisi K-Means++ terpilih dapat diulang pada berbagai inisialisasi acak. Klaim kebaruan bersifat kontekstual dan metodologis, bukan klaim menciptakan algoritma clustering baru. Secara khusus, penggunaan aturan Pareto menggabungkan pemisahan internal dan keterulangan inisialisasi sehingga jumlah cluster terpilih tidak ditentukan hanya dari satu metrik.

LAMPIRAN B. DEFINISI EKSPERIMEN FORMAL

Misalkan C menyatakan suatu kohort kurikulum, dan $X_C \in R^{(n_C \times p_C)}$ menyatakan matriks nilai siswa-per-mata-pelajaran yang lengkap dan telah diimputasi. Setelah standardisasi, Z_C digunakan sebagai input untuk seluruh algoritma clustering. Untuk K-Means, tujuan untuk kandidat k adalah meminimalkan $J=\Sigma_{(r=1)}^{k} \Sigma_{(z_i \in S_r)} \|z_i-\mu_r\|^2$, dengan S_r sebagai cluster r dan μ_r sebagai centroidnya. Tujuan tersebut bersifat non-konveks terhadap penetapan dan centroid secara bersama; akibatnya, solusi dapat bergantung pada inisialisasi. K-Means++ menangani tahap seeding dengan memprioritaskan titik yang jauh dari pusat yang sudah ada, tetapi tidak menjamin optimum global.

Untuk suatu partisi kandidat P, nilai Silhouette untuk observasi i adalah $s(i)=(b(i)-a(i))/\max\{a(i),b(i)\}$, dengan a(i) sebagai jarak intra-cluster rata-rata dan b(i) sebagai jarak rata-rata terkecil ke cluster lain. Skor tingkat kohort merupakan rata-rata s(i) pada seluruh observasi yang dievaluasi. Davies–Bouldin Index dihitung dari sebaran dalam cluster S_r dan jarak centroid M_{rs}; untuk setiap cluster dipilih rasio maksimum $(S_r+S_s)/M_{rs}$, dan indeks merupakan rata-rata dari nilai maksimum tersebut. Nilai DBI yang lebih rendah menunjukkan sebaran relatif dalam cluster yang lebih rendah dan pemisahan centroid yang lebih besar.

Misalkan P_u dan P_v adalah partisi yang dihasilkan oleh dua seed acak u dan v. Adjusted Rand Index dihitung dari tabel kontingensi berbasis pasangan dan menyesuaikan kesesuaian Rand terhadap nilai yang diharapkan di bawah model partisi acak. ARI=1 menunjukkan partisi identik, nilai mendekati nol menunjukkan kesesuaian pada tingkat peluang, dan nilai negatif menunjukkan kesesuaian yang lebih rendah daripada yang diharapkan secara kebetulan. Eksperimen menggunakan seluruh pasangan seed tak berurutan, bukan perbandingan terhadap partisi referensi berlabel. Oleh karena itu, nilai ARI dalam paper ini merupakan ukuran keterulangan antar-inisialisasi dan tidak boleh disebut sebagai akurasi prediktif.

Seleksi Pareto dapat dinyatakan sebagai berikut. Kandidat k_a mendominasi k_b jika $Sil(k_a) \geq Sil(k_b)$, $ARI(k_a) \geq ARI(k_b)$, dan $DBI(k_a) \leq DBI(k_b)$, dengan setidaknya satu ketidaksetaraan yang ketat. Himpunan yang tidak didominasi K* berisi kandidat yang tidak didominasi oleh kandidat lain. Seleksi akhir adalah argmax atas K* berdasarkan pengurutan leksikografis (Silhouette, ARI, −DBI). Aturan deterministik ini diterapkan secara independen pada setiap kohort. Dengan demikian, hasil k=2 pada kelima kohort merupakan konsekuensi dari vektor metrik yang diamati, bukan jumlah cluster yang ditentukan secara manual.

Perbedaan penting adalah bahwa ketiga kriteria tidak independen secara statistik. Silhouette dan DBI sama-sama menggunakan jarak dalam ruang fitur yang telah distandardisasi, sedangkan ARI membandingkan penetapan label yang dihasilkan dari pengulangan. Prosedur Pareto merupakan aturan keputusan yang transparan, bukan uji hipotesis statistik formal. Prosedur ini tidak memberikan interval kepercayaan untuk jumlah cluster dan sebaiknya dilengkapi dengan resampling atau validasi eksternal pada penelitian mendatang.

LAMPIRAN C. GRID METRIK K-MEANS++ LENGKAP

Tabel IX memberikan nilai rata-rata untuk setiap k yang diuji pada setiap kohort. Tabel tersebut membuat proses seleksi dapat ditelusuri dan menunjukkan perubahan sistematis pada kriteria internal ketika jumlah cluster meningkat. Dalam eksperimen ini, Silhouette secara umum menurun dan DBI secara umum meningkat ketika k bertambah melewati dua. Rata-rata ARI juga cenderung menurun untuk k yang lebih besar, meskipun terdapat beberapa variasi lokal. Pola tersebut menjelaskan mengapa k=2 menjadi satu-satunya kandidat Pareto pada setiap kohort berdasarkan arah tujuan yang dipilih.

TABEL IX. GRID METRIK RATA-RATA K-MEANS++ LENGKAP

Kohort	k	Silhouette	DBI	ARI Berpasangan
K X	2	0.3064	1.2047	1.0000
K X	3	0.2041	1.5010	0.7410
K X	4	0.1587	1.7252	0.7788
K X	5	0.1283	2.0848	0.6452
K X	6	0.1178	2.2305	0.5928
K X	7	0.1074	2.3203	0.5715
K X	8	0.0988	2.3865	0.5261
K XI (01-04)	2	0.3165	1.1787	0.9600
K XI (01-04)	3	0.1992	1.4933	0.5822
K XI (01-04)	4	0.1675	1.6554	0.6555
K XI (01-04)	5	0.1428	1.7948	0.5787
K XI (01-	6	0.1248	1.9118	0.5168

K XI (01-04)	7	0.1162	1.9398	0.4939
K XI (01-04)	8	0.1116	1.9482	0.4575
K XI (05-12)	2	0.2887	1.2813	0.9498
K XI (05-12)	3	0.2148	1.4507	0.8041
K XI (05-12)	4	0.1590	1.7195	0.6720
K XI (05-12)	5	0.1358	1.8683	0.5629
K XI (05-12)	6	0.1278	1.8832	0.4802
K XI (05-12)	7	0.1204	1.8815	0.4581
K XI (05-12)	8	0.1197	1.8575	0.4613
K XII (MIPA)	2	0.2624	1.4601	0.9711
K XII (MIPA)	3	0.1687	1.7986	0.8922
K XII (MIPA)	4	0.1246	2.1729	0.6009
K XII (MIPA)	5	0.1081	2.2710	0.5221
K XII (MIPA)	6	0.0967	2.3264	0.4594
K XII (MIPA)	7	0.0914	2.3132	0.4417
K XII (MIPA)	8	0.0860	2.3498	0.4025
K XII (IPS)	2	0.2299	1.5038	1.0000
K XII (IPS)	3	0.1622	1.7284	0.7510
K XII (IPS)	4	0.1288	2.0242	0.5089
K XII (IPS)	5	0.1138	2.0860	0.4375
K XII (IPS)	6	0.1067	2.0977	0.4171
K XII (IPS)	7	0.1055	2.0270	0.4078
K XII (IPS)	8	0.1019	2.0085	0.4024

LAMPIRAN D. INTERPRETASI TINGKAT KOHORT

Kelas X berisi 426 siswa yang direpresentasikan oleh 16 fitur mata pelajaran. Solusi dua cluster terpilih membagi kohort menjadi 201 siswa dengan profil skor lebih rendah (47.2%) dan 225 siswa dengan profil skor lebih tinggi (52.8%). Tiga perbedaan centroid absolut terbesar terdapat pada Kimia (23.7 poin), Biologi (20.1), dan PPKn (19.4). Rata-rata Silhouette adalah 0.3064, DBI adalah 1.2047, dan ARI berpasangan adalah 1.0000. Ini merupakan solusi dengan keterulangan inisialisasi paling tinggi, dalam arti seluruh 30 run menghasilkan partisi identik, tetapi Silhouette tetap menunjukkan pemisahan yang sedang, bukan kuat.

Kelas XI 01–04 berisi 142 siswa dan 13 fitur. Profil skor lebih rendah mencakup 63 siswa (44.4%), sedangkan profil skor lebih tinggi mencakup 79 siswa (55.6%). Selisih terbesar terdapat pada Bahasa Indonesia (18.7), Bahasa Jawa (18.5), dan Bahasa Inggris Lanjut (17.6). Nilai rata-rata Silhouette 0.3165 merupakan yang tertinggi dari kelima solusi terpilih, sedangkan DBI 1.1787 merupakan yang terendah. Rata-rata ARI berpasangan 0.9600 tergolong tinggi, meskipun simpangan baku yang tidak nol menunjukkan masih terdapat sedikit variasi akibat inisialisasi.

Kelas XI 05–12 berisi 284 siswa dan 10 fitur mata pelajaran. Terdapat 99 siswa dengan profil skor lebih rendah (34.9%) dan 185 siswa dengan profil skor lebih tinggi (65.1%). Selisih terbesar terdapat pada Penjasorkes (20.0), Seni Budaya (16.5), dan Bahasa Indonesia (16.5). Rata-rata Silhouette adalah 0.2887, DBI 1.2813, dan ARI berpasangan 0.9498. Kohort ini memiliki rata-rata ARI terendah di antara solusi terpilih, tetapi nilainya tetap tinggi. Proporsi kelompok skor lebih tinggi yang relatif besar tidak boleh diinterpretasikan sebagai bukti bahwa kohort tersebut secara akademik lebih kuat daripada kohort lain karena matriks dan kombinasi mata pelajarannya berbeda.

Kelas XII MIPA berisi 283 siswa dan 15 fitur mata pelajaran. Profil skor lebih rendah mencakup 107 siswa (37.8%), sedangkan profil skor lebih tinggi mencakup 176 siswa (62.2%). Fisika memiliki selisih centroid terbesar (21.5), diikuti Matematika Wajib (18.6) dan Bahasa Inggris Wajib (18.0). Rata-rata Silhouette adalah 0.2624 dan DBI 1.4601. Rata-rata ARI berpasangan sebesar 0.9711 menunjukkan keterulangan inisialisasi yang tinggi. Selisih mata pelajaran memberikan dasar deskriptif bagi guru untuk meninjau area kurikulum tersebut, tetapi tidak menetapkan bahwa mata pelajaran tersebut menyebabkan perbedaan prestasi akademik secara keseluruhan.

Kelas XII IPS berisi 142 siswa dan 14 fitur mata pelajaran. Ini merupakan satu-satunya kohort dengan profil skor lebih rendah yang lebih besar: 75 siswa (52.8%) dibandingkan 67 siswa (47.2%) pada profil skor lebih tinggi. Selisih terbesar terdapat pada PPKn (18.5), Bahasa Jawa (17.1), dan Ekonomi (16.2). Silhouette sebesar 0.2299 merupakan yang terendah di antara solusi terpilih dan DBI 1.5038 merupakan yang tertinggi, sedangkan rata-rata ARI berpasangan adalah 1.0000. Dengan demikian, partisi sangat dapat diulang tetapi memiliki pemisahan internal terlemah dari kelima kohort. Ini merupakan contoh jelas mengapa keterulangan tidak boleh disamakan dengan kualitas cluster.

LAMPIRAN E. INTERPRETASI TERPERINCI BENCHMARK ALGORITMA PEMBANDING

K-Means dengan inisialisasi acak memberikan referensi untuk pengaruh strategi inisialisasi. Konfigurasi terbaiknya pada setiap kohort adalah k=2 dengan n_init=10. Nilai Silhouette terbaik adalah 0.3064 untuk Kelas X, 0.3174 untuk Kelas XI 01–04, 0.2922 untuk Kelas XI 05–12, 0.2610 untuk Kelas XII MIPA, dan 0.2299 untuk Kelas XII IPS. Hasil tersebut mendekati solusi K-Means++ terpilih. Perbedaan kecil tidak boleh diinterpretasikan secara berlebihan karena hasil K-Means++ merangkum 30 run dengan satu inisialisasi, sedangkan baseline acak menggunakan sepuluh inisialisasi dalam satu fitting estimator.

BIRCH menghasilkan kandidat valid untuk setiap kohort, dan konfigurasi terbaiknya adalah dua cluster dengan threshold=0.5 pada kelima kohort. Nilai Silhouette-nya masing-masing adalah 0.2833, 0.3155, 0.3733, 0.2599, dan 0.2409 untuk Kelas X, Kelas XI 01–04, Kelas XI 05–12, Kelas XII MIPA, dan Kelas XII IPS. Hasil terkuat terdapat pada Kelas XI 05–12, ketika Silhouette BIRCH sebesar 0.3733 dan DBI 0.9883 lebih baik daripada nilai K-Means++ terpilih. Hal ini menunjukkan bahwa geometri clustering yang berbeda mungkin lebih sesuai untuk kohort tersebut pada konfigurasi yang diuji. Namun, hal ini tidak

menerapkan bahwa BIRCH lebih disukai untuk seluruh kohort.

GMM menghasilkan kandidat valid dengan dua hingga delapan komponen pada setiap kohort. Kandidat terbaik berdasarkan Silhouette menggunakan dua komponen pada setiap kohort. Nilai Silhouette terbaiknya adalah 0.2014, 0.2496, 0.2369, 0.2107, dan 0.1307 dalam urutan kohort yang digunakan sebelumnya. Dalam eksperimen ini, nilai tersebut lebih rendah daripada K-Means++ dan BIRCH pada sebagian besar kohort. Hasil GMM sensitif terhadap asumsi kovarians dan pengaturan inisialisasi; hanya konfigurasi full-covariance dengan regularisasi dan tiga inisialisasi yang ditentukan yang dievaluasi.

Mean Shift menghasilkan partisi valid hanya untuk Kelas XI 05–12 dan Kelas XII MIPA. Bandwidth terpilih diestimasi menggunakan kuantil 0.2 dan maksimal 500 sampel. Nilai Silhouette yang dihasilkan adalah 0.3379 untuk Kelas XI 05–12 dan 0.1902 untuk Kelas XII MIPA. Tidak diperoleh kandidat valid untuk tiga kohort lainnya dengan prosedur estimasi bandwidth ini. Kegagalan tersebut dilaporkan sebagai tidak adanya partisi valid, bukan sebagai bukti bahwa Mean Shift tidak pernah dapat diterapkan pada data tersebut.

DBSCAN menghasilkan kandidat valid pada Kelas X, Kelas XI 01–04, dan Kelas XI 05–12. Namun, kandidat terpilih terbaik memiliki rasio noise masing-masing 91.3%, 72.5%, dan 95.1%. Sebagai contoh, kandidat Kelas XI 05–12 hanya mengevaluasi 14 dari 284 siswa. Silhouette tinggi yang dihitung pada subset sekecil itu tidak menggambarkan keseluruhan kohort. Perbandingan masa depan sebaiknya memasukkan kriteria yang disesuaikan dengan cakupan atau secara eksplisit menetapkan persyaratan cakupan penetapan minimum sebelum solusi berbasis kepadatan dianggap dapat diterima.

Di antara kelima metode, tidak ada satu algoritma yang mendominasi seluruh kohort dan seluruh dimensi evaluasi. Benchmark berguna sebagai perbandingan diagnostik terhadap kandidat partisi pada grid parameter yang diuji. Benchmark tidak boleh disajikan sebagai peringkat algoritma yang definitif. Perbandingan yang lebih ketat akan mengalokasikan anggaran tuning yang sebanding, menggunakan evaluasi bertingkat atau held-out jika memungkinkan, melaporkan runtime dan cakupan, mengulangi metode stokastik pada berbagai seed, serta mengevaluasi stabilitas partisi yang dihasilkan terhadap perturbasi sampel siswa.

LAMPIRAN F. CHECKLIST REPRODUKTIBILITAS DAN TATA KELOLA DATA

Pengaturan komputasi utama yang diperlukan untuk mereproduksi eksperimen adalah: source sheet=Sheet1; coverage_subject=0.80; coverage_student=0.80; rentang k=2–8; seeds=0–29; initialization=k-means++; n_init=1; max_iter=500; reference K-Means initialization=random; reference k=3; reference n_init=10; reference random_state=42; dan scaler=StandardScaler. Ambang sensitivitas adalah 0.70, 0.80, dan 0.90. Konfigurasi algoritma pembanding dilaporkan pada Bagian IV-F. Parameter tersebut harus disimpan bersama notebook dan workbook hasil ekspor.

Audit preprocessing harus dijalankan kembali setiap kali workbook sumber berubah. Secara khusus, jumlah penanda “Belum Ikut” dan “Kristen”, kunci siswa–mata pelajaran yang duplikat, label kelas yang dinormalisasi, dan jumlah akhir siswa yang dipertahankan harus diperiksa. Perubahan pada salah satu elemen tersebut dapat mengubah matriks fitur dan harus memicu eksekusi ulang seluruh pipeline. Paper tidak boleh diperbarui dengan mengedit metrik secara manual dan terpisah sementara gambar atau tabel masih berasal dari run sebelumnya.

Artefak penelitian yang diekspor hanya boleh berisi hasil agregat dan output analitis yang telah dianonimkan. Nama siswa, nomor absensi, field KEY untuk linkage, dan label cluster individual harus dikeluarkan dari output publik. Jika repositori publik disiapkan, workbook yang berisi data tingkat baris tidak boleh diunggah. Repositori sebaiknya berisi notebook dengan instruksi pemuatan path yang aman, kamus data, tabel hasil agregat, dan README yang menjelaskan lingkungan serta pengaturan parameter.

Sebelum profil digunakan dalam praktik sekolah, pemilik data harus mengonfirmasi interpretasi penanda nonnumerik dan lima pemetaan kohort. Guru perlu meninjau apakah selisih centroid terbesar selaras dengan bukti pembelajaran di kelas saat ini. Suatu profil harus digunakan untuk memulai percakapan mengenai dukungan belajar, bukan untuk memberi label permanen kepada siswa. Pembedaan antara clustering deskriptif dan asesmen berisiko tinggi sangat penting untuk penggunaan data pendidikan yang bertanggung jawab.

LAMPIRAN G. PEMBAHASAN EKSTENSIF TENTANG RANCANGAN EKSPERIMEN

Representasi fitur merupakan salah satu keputusan paling menentukan dalam penelitian ini. Workbook asli disimpan dalam format long, ketika seorang siswa dapat menyumbangkan beberapa baris yang sesuai dengan mata pelajaran yang berbeda. Clustering secara langsung pada struktur ini akan memperlakukan setiap record mata pelajaran sebagai observasi independen dan tidak menghasilkan profil tingkat siswa. Pivot berdasarkan siswa dan mata pelajaran mengubah unit analisis dari record nilai menjadi siswa. Transformasi ini diperlukan karena pertanyaan penelitian berkaitan dengan kemiripan antar-siswa berdasarkan pola nilai mata pelajaran mereka. Kunci siswa memberikan identitas baris selama transformasi ini, tetapi tidak digunakan sebagai prediktor numerik.

Pemisahan kohort juga merupakan bagian penting dari validitas perhitungan jarak. Jika Kelas X, Kelas XI, Kelas XII MIPA, dan Kelas XII IPS digabungkan menjadi satu matriks, banyak kolom mata pelajaran akan secara struktural tidak tersedia untuk sebagian siswa karena mata pelajaran tidak ditawarkan secara seragam. Memperlakukan ketidakhadiran struktural tersebut sebagai nol akan menimbulkan ketidakmiripan artifisial. Imputasi median di seluruh jenjang juga dapat mencampurkan distribusi kurikulum dan penilaian yang berbeda. Rancangan lima kohort mengurangi masalah ini dengan membangun fitur mata pelajaran dan imputasi dalam kelompok yang memiliki penawaran mata pelajaran lebih sebanding. Namun, pemetaan kohort yang tepat tetap perlu diverifikasi terhadap kurikulum dan jadwal resmi karena label kelas saja merupakan proksi yang tidak sempurna untuk keikutsertaan mata pelajaran.

Ambang cakupan mata pelajaran 80% dipilih sebagai kompromi antara mempertahankan kumpulan mata pelajaran yang luas dan menghindari kolom dengan missingness yang ekstensif. Ambang kelengkapan siswa juga mengurangi pengaruh siswa yang vektornya akan mengandung proporsi nilai imputasi yang besar. Analisis sensitivitas menunjukkan bahwa jumlah siswa yang dipertahankan tidak berubah pada

cakupan fitur 70%, 80%, dan 90%. Hal ini terjadi karena filter siswa diterapkan setelah seleksi fitur dan karena matriks yang diamati cukup lengkap untuk sebagian besar kohort. Kelas XII IPS merupakan satu-satunya kohort yang jumlah fitur terpilihnya berubah antara ambang 70% dan 80%. Dengan demikian, hasil sensitivitas mendukung stabilitas dimensi matriks, tetapi tidak membuktikan bahwa setiap penetapan individual akan tetap sama pada ambang alternatif.

Imputasi median sesuai sebagai baseline yang transparan untuk sejumlah kecil sel yang hilang, tetapi memiliki keterbatasan. Median merupakan estimasi tendensi sentral dan tidak mempertimbangkan hubungan antar-mata-pelajaran, mekanisme missingness pada tingkat siswa, atau alasan suatu penilaian tidak diselesaikan. Jika missingness berkaitan dengan prestasi siswa, nilai imputasi dapat membiaskan jarak yang dihasilkan. Penelitian mendatang dapat membandingkan imputasi median kohort dengan imputasi k-nearest-neighbor, imputasi iteratif, atau metode yang menghitung jarak hanya pada mata pelajaran yang sama-sama teramati. Alternatif apa pun harus dievaluasi tanpa kebocoran informasi dari data yang ditahan jika tujuan penelitian nantinya berubah dari segmentasi deskriptif menjadi prediksi.

Standardisasi z-score memberikan setiap mata pelajaran rata-rata sekitar nol dan simpangan baku sekitar satu dalam kohort. Hal ini penting karena tujuan K-Means didasarkan pada jarak Euclidean kuadrat, dan fitur dengan varians numerik yang lebih besar dapat mendominasi tujuan jika tidak distandardisasi. Standardisasi tidak menyamakan reliabilitas, kesalahan pengukuran, atau kepentingan kurikulum. Standardisasi hanya mengubah skala variasi yang diamati. Jika sekolah menggunakan rentang nilai atau tingkat kesulitan penilaian yang berbeda antar-mata-pelajaran, vektor nilai yang telah distandardisasi harus diinterpretasikan sebagai posisi relatif dalam kohort, bukan sebagai ukuran absolut penguasaan mata pelajaran.

Rancangan repeated-seed mengisolasi sensitivitas K-Means++ terhadap inisialisasi sambil mempertahankan matriks data tetap. Untuk setiap k, eksperimen menjalankan estimator sebanyak 30 kali, dengan satu inisialisasi pada setiap run. Hal ini berbeda dari menetapkan n_init=30 dalam satu pemanggilan estimator: cara kedua hanya mempertahankan run terbaik berdasarkan inertia, sedangkan rancangan saat ini mempertahankan partisi terpisah sehingga ARI berpasangan dapat dihitung. Dengan demikian, rancangan mendukung pernyataan eksplisit mengenai keterulangan inisialisasi. Rancangan ini tidak mengukur ketidakpastian yang disebabkan oleh siswa yang dipilih, mata pelajaran yang disertakan, atau semester yang diamati.

Pemilihan k=2 pada kelima kohort didorong oleh pola metrik gabungan. Untuk solusi terpilih, k=2 memiliki rata-rata Silhouette tertinggi di antara nilai yang diuji pada setiap kohort, DBI terendah atau mendekati terendah, dan keterulangan inisialisasi terkuat. Ketika k meningkat, algoritma membagi ruang fitur menjadi kelompok yang semakin kecil, tetapi partisi tambahan yang dihasilkan tidak memperbaiki ketiga kriteria pada data yang diamati. Hal ini tidak berarti bahwa dua cluster merupakan satu-satunya representasi bermakna dari prestasi akademik. Jika sekolah membutuhkan kategori dukungan yang lebih terperinci, tujuan yang berbeda atau analisis lanjutan hierarkis dapat lebih sesuai. Keputusan tersebut harus didasarkan pada kasus penggunaan pendidikan yang jelas, bukan preferensi terhadap jumlah kategori yang lebih banyak.

Baseline K-Means dengan inisialisasi acak pada k=3 membantu memberikan konteks terhadap solusi terpilih, tetapi bukan perbandingan terkontrol yang hanya menguji metode inisialisasi. Baik k maupun protokol inisialisasi berbeda. Untuk mengisolasi pengaruh inisialisasi secara lebih bersih, eksperimen mendatang sebaiknya membandingkan K-Means++ dan inisialisasi acak pada nilai k yang sama, menggunakan anggaran seed yang sepadan, dan melaporkan distribusi Silhouette, DBI, inertia, runtime, dan ARI. Eksperimen Random K-Means pembanding saat ini sebagian menjawab hal tersebut dengan mengevaluasi k=2–8 menggunakan n_init=10, tetapi prosedur seleksinya tetap berbeda dari rancangan K-Means++ satu-start yang diulang.

Benchmark algoritma pembanding juga harus diinterpretasikan dalam kaitannya dengan asumsi algoritma. K-Means dan BIRCH menghasilkan pengelompokan berorientasi centroid atau kelompok kompak, sedangkan GMM memodelkan observasi melalui campuran distribusi probabilitas. DBSCAN mengidentifikasi wilayah padat dan memberi label noise pada observasi di luar wilayah tersebut. Mean Shift mengestimasi mode dalam distribusi fitur dan dapat menghasilkan jumlah cluster yang bergantung pada data. Karena algoritma tersebut tidak memiliki asumsi yang identik, nilai Silhouette mentah saja tidak dapat menetapkan peringkat yang secara universal adil. Cakupan, jumlah cluster, sensitivitas parameter, runtime, dan stabilitas harus dipertimbangkan secara bersama.

DBSCAN sangat ilustratif. Nilai Silhouette tertingginya diperoleh setelah sebagian besar observasi dikecualikan sebagai noise. Jika tujuan penerapan adalah menyediakan profil untuk setiap siswa, solusi yang hanya menetapkan sebagian kecil siswa secara operasional tidak lengkap. Salah satu protokol masa depan dapat mensyaratkan cakupan penetapan minimum, misalnya 80% atau 90%, sebelum konfigurasi DBSCAN memenuhi syarat untuk dibandingkan. Alternatif lain adalah melaporkan hasil dua bagian: kualitas internal pada observasi yang ditetapkan dan cakupan pada seluruh kohort. Penelitian ini melaporkan rasio noise secara eksplisit tetapi tidak menetapkan ambang cakupan minimum, sehingga skor terpilih DBSCAN harus dibaca sebagai metrik subset.

Perbandingan dengan BIRCH juga memberikan pelajaran. BIRCH mencapai Silhouette yang lebih tinggi daripada K-Means++ untuk Kelas XI 05–12 dengan threshold=0.5 dan dua cluster. Hal ini menunjukkan bahwa geometri kohort tersebut mungkin direpresentasikan secara berbeda oleh kedua metode. Namun, hasil tersebut didasarkan pada satu pengaturan threshold dan prosedur seleksi kandidat yang menggunakan Silhouette pada data yang sama. Benchmark yang lebih lengkap akan melakukan tuning threshold dan branching factor BIRCH, mengulangi prosedur pada rentang parameter yang wajar, dan menilai stabilitas penetapannya. Hasil saat ini merupakan sinyal yang berguna untuk tindak lanjut, bukan rekomendasi algoritma final.

Interpretasi pendidikan harus tetap dilakukan secara hati-hati. Profil skor lebih rendah didefinisikan hanya berdasarkan rata-rata yang lebih rendah pada centroid mata pelajaran dari partisi terpilih. Hal ini tidak berarti bahwa setiap siswa dalam cluster tersebut memiliki nilai rendah pada setiap mata pelajaran. Seorang siswa dapat berada dalam profil skor lebih rendah secara keseluruhan dan tetap memiliki kekuatan relatif pada satu atau beberapa mata pelajaran. Sebaliknya, siswa dalam profil skor lebih tinggi dapat memiliki nilai rendah pada mata pelajaran tertentu.

Oleh karena itu, tabel centroid tingkat mata pelajaran merupakan pelengkap penting bagi jumlah keanggotaan cluster. Jika sekolah menggunakan output tersebut untuk merencanakan dukungan, sekolah harus memeriksa pola aktual pada tingkat mata pelajaran, bukan hanya mengandalkan satu label cluster.

Selisih centroid merupakan perbedaan deskriptif antara rata-rata nilai dua cluster. Selisih tersebut bukan ukuran efek terstandardisasi, uji signifikansi statistik, atau estimasi kausal. Selisih dapat mencerminkan berbagai faktor, termasuk pengetahuan awal, tingkat kesulitan penilaian, kesempatan pembelajaran, kehadiran, kondisi belajar di rumah, atau variasi pengukuran. Tidak satu pun variabel penjelas tersebut tersedia dalam workbook PAS yang disediakan. Oleh karena itu, tidak tepat menyimpulkan bahwa mata pelajaran dengan selisih besar secara inheren sulit, bahwa seorang guru tidak efektif, atau bahwa keanggotaan cluster disebabkan oleh karakteristik siswa tertentu.

Workflow operasional dapat menggunakan profil dalam tiga tahap. Pertama, tim akademik meninjau ringkasan tingkat kohort untuk mengidentifikasi mata pelajaran dengan selisih centroid yang relatif besar. Kedua, guru mata pelajaran memeriksa asesmen formatif dan bukti pembelajaran di kelas untuk menentukan apakah pola tersebut sesuai dengan tujuan atau topik pembelajaran tertentu. Ketiga, tim memutuskan apakah diperlukan asesmen diagnostik tambahan, pengayaan, atau dukungan pembelajaran yang ditargetkan. Output clustering harus menjadi bahan pertimbangan dalam peninjauan, bukan secara otomatis menentukan intervensi. Evaluasi tindak lanjut kemudian dapat memeriksa apakah aktivitas dukungan berkaitan dengan perubahan hasil penilaian berikutnya, meskipun klaim kausal memerlukan rancangan penelitian yang sesuai.

Kekhawatiran tambahan adalah potensi kesalahan interpretasi ekologis. Centroid kohort menggambarkan pola rata-rata suatu kelompok, bukan pengalaman setiap siswa secara individual. Perbedaan tingkat kelompok tidak dapat diterapkan kepada setiap anggota tanpa memeriksa hasil mata pelajaran individual. Kehati-hatian yang sama berlaku ketika membandingkan kohort: setiap kohort menggunakan himpunan fitur yang berbeda dan distandardisasi secara independen. Dengan demikian, nilai Silhouette atau DBI dapat dibandingkan sebagai diagnostik deskriptif, tetapi nilai centroid rata-rata pada skala asli tidak boleh diperlakukan sebagai peringkat terstandardisasi yang sama untuk seluruh jenjang.

Terakhir, reproduktibilitas paper bergantung pada pemeliharaan versi workbook sumber dan konfigurasi notebook yang tepat. Perubahan pada label kelas, penyelesaian duplikasi, penanganan penanda nonnumerik, atau nilai skor dapat mengubah matriks pivot. Notebook sebaiknya mencatat versi paket, tanggal eksekusi, checksum file sumber, dan checksum workbook keluaran pada revisi mendatang. Paper saat ini melaporkan pengaturan yang mendefinisikan eksperimen dan output numerik yang dihitung ulang dari workbook terlampir. Gambar dan tabel yang dihasilkan harus dibuat ulang setiap kali dataset sumber atau kode berubah.

LAMPIRAN H. RUANG LINGKUP PENELITIAN DAN BATASAN KLAIM

Penelitian ini bersifat deskriptif dan eksploratif. Penelitian menjawab bagaimana nilai mata pelajaran PAS dapat ditransformasikan menjadi matriks spesifik kohort, bagaimana kandidat jumlah cluster dapat dipilih dari metrik internal dan keterulangan inisialisasi, serta profil nilai umum apa yang terlihat pada partisi terpilih. Penelitian ini tidak menjawab apakah seorang siswa akan lulus atau gagal pada ujian mendatang, apakah seorang siswa berisiko putus sekolah, atau apakah intervensi tertentu akan meningkatkan prestasi. Pertanyaan tersebut memerlukan outcome berlabel, record longitudinal, dan rancangan evaluasi yang sesuai untuk prediksi atau inferensi kausal.

Pembedaan antara segmentasi dan prediksi penting karena beberapa referensi yang digunakan mempelajari prediksi atau peringatan dini [4]–[6], [11]. Metrik prediktif yang mereka laporkan tidak dapat dipindahkan ke paper ini. Demikian pula, studi berbasis jejak digital [7], [8] menganalisis keterlibatan atau perilaku belajar yang tidak terdapat dalam workbook PAS. Penelitian ini menggunakan literatur untuk menetapkan relevansi EDM dan memotivasi pilihan metodologis, sambil menjaga klaim penelitian tetap berada dalam cakupan data nilai yang diamati.

Penggunaan istilah “berbasis stabilitas” pada judul secara khusus merujuk pada penilaian inisialisasi berulang menggunakan ARI berpasangan. Istilah tersebut tidak boleh diinterpretasikan sebagai klaim stabilitas penuh terhadap sampling, waktu, atau perturbasi fitur. Paper secara eksplisit memisahkan keterulangan algoritmik dari robustness yang lebih luas. Revisi mendatang dapat memperkuat klaim judul dengan menambahkan analisis stabilitas bootstrap atau subsampling, tetapi prosedur tersebut belum menjadi bagian dari eksperimen Colab saat ini.

Frasa “skor lebih tinggi” dan “skor lebih rendah” hanya digunakan untuk memberi label pada dua centroid setelah diurutkan berdasarkan rata-rata nilai mata pelajaran pada skala asli. Label tersebut bersifat relatif terhadap kohort dan tidak boleh diterjemahkan menjadi kategori “siswa berprestasi tinggi” dan “siswa berprestasi rendah” tanpa benchmark yang disetujui sekolah. Tidak ada klasifikasi pendidikan berbasis ambang yang disertakan. Pembedaan ini diperlukan untuk mencegah output eksploratif tanpa supervisi berubah menjadi pemeringkatan siswa yang tidak didukung.

Keterbatasan utama dataset saat ini adalah bahwa dataset merupakan satu snapshot penilaian. Paper tidak memiliki record semester sebelumnya, rangkaian asesmen formatif, kehadiran, konteks demografis, atau record intervensi kelas. Akibatnya, segmentasi tidak dapat mengungkap lintasan siswa, penyebab perbedaan prestasi, atau keberlangsungan suatu profil. Ekstensi longitudinal dengan nama mata pelajaran, versi kurikulum, dan skala penilaian yang diharmonisasi diperlukan untuk mempelajari perpindahan antarprofil dari waktu ke waktu.

LAMPIRAN I. PROSEDUR BERTAHAP UNTUK EKSEKUSI YANG DAPAT DIREPRODUKSI

Urutan eksekusi dimulai dengan memuat Sheet1 dari workbook sumber dan mempertahankan field asli untuk audit. NILAI dikonversi menjadi representasi numerik menggunakan coercion untuk entri nonnumerik. Label kelas dinormalisasi sebelum kunci siswa komposit dibentuk. Notebook kemudian memeriksa pasangan siswa–mata pelajaran yang berulang dan memeriksa apakah nilai numerik tersedia bersamaan dengan penanda nonnumerik “Kristen”. Record numerik diprioritaskan dan satu baris dipertahankan untuk setiap kunci dan mata pelajaran. Aturan ini sengaja dibuat eksplisit karena penanganan duplikasi dapat memengaruhi matriks mata pelajaran.

tahap berikutnya menetapkan setiap kelas yang telah dinormalisasi ke salah satu dari lima kohort. Kelas X ditetapkan sebagai satu kohort. Kelas XI dibagi menjadi kelas 01–04 dan 05–12. Kelas XII dibagi menjadi kelompok MIPA dan IPS. Label kohort yang dihasilkan dilampirkan pada setiap record sebelum operasi pivot. Untuk setiap kohort, notebook membuat matriks siswa-per-mata-pelajaran, memilih fitur yang memenuhi ambang cakupan, menyaring siswa yang memenuhi ambang kelengkapan, mencatat jumlah sel yang hilang, mengimputasi sel tersebut dengan median mata pelajaran, menghapus kolom dengan varians nol, dan menstandardisasi nilai yang tersisa.

Untuk setiap kohort dan setiap k dari dua hingga delapan, notebook melakukan fitting terhadap 30 model K-Means++ terpisah. Setiap fitting menggunakan satu inisialisasi dan random_state yang berbeda. Setelah setiap fitting, label model dipertahankan di memori, dan nilai Silhouette serta DBI dihitung pada matriks kohort lengkap. Ke-30 vektor label kemudian dibandingkan secara berpasangan menggunakan ARI. Notebook menyimpan rata-rata dan simpangan baku dari ketiga metrik. Notebook juga melakukan fitting referensi acak dengan k=3 yang tetap, menghitung profil centroid pada skala asli untuk partisi terpilih, dan mengevaluasi ketiga ambang cakupan.

Tahap algoritma pembanding menggunakan matriks yang sama dan telah distandardisasi. Tahap ini mengiterasi grid kandidat untuk Random K-Means, DBSCAN, BIRCH, dan GMM, serta mengestimasi bandwidth untuk Mean Shift. Setiap kandidat diperiksa validitas metriknya. Untuk DBSCAN, observasi noise dimask sebelum metrik internal dihitung. Kandidat terpilih untuk setiap algoritma dan kohort adalah kandidat valid dengan Silhouette tertinggi, dengan DBI digunakan sebagai kriteria pengurutan sekunder. Daftar kandidat lengkap dan ringkasan status harus dipertahankan agar hasil valid yang tidak tersedia tidak disalahartikan sebagai algoritma yang tidak pernah dijalankan.

Tahap akhir mengekspor tabel agregat dan profil centroid kohort. Output tidak boleh berisi nama siswa, nomor absensi, kunci komposit, atau label cluster individual. Pemeriksaan integritas eksperimen memverifikasi bahwa kelima kohort tersedia, 35 konfigurasi kohort-k utama tersedia, setiap konfigurasi berisi 30 run, dan masing-masing memiliki 435 nilai ARI berpasangan. Populasi yang diharapkan dipertahankan adalah 1.277 siswa. Assertion yang gagal harus diperlakukan sebagai alasan untuk menyelidiki pipeline data, bukan dilewati hanya untuk menghasilkan file keluaran.

Sebelum pengumpulan akhir, penulis harus menjalankan notebook lengkap di lingkungan Google Colab target dari runtime yang bersih. Workbook sumber harus dipasang dari lokasi Drive yang berwenang, dan notebook harus dijalankan dari sel pertama hingga sel ekspor tanpa bergantung pada variabel lama. Workbook yang diekspor kemudian harus diperiksa terhadap tabel dalam manuskrip. Pemeriksaan end-to-end ini penting karena notebook dapat berisi kode yang benar sementara workbook keluaran atau tabel manuskrip sebelumnya merefleksikan versi data yang lebih lama.

LAMPIRAN J. INTERPRETASI TRADE-OFF METRIK INTERNAL

Penurunan Silhouette yang diamati ketika k meningkat konsisten dengan solusi dua kelompok terpilih yang memberikan kohesi dan pemisahan rata-rata terkuat di antara kandidat yang diuji. Namun, koefisien Silhouette merupakan nilai rata-rata dan dapat menyembunyikan variasi antarobservasi individual. Beberapa siswa dapat berada dekat batas keputusan meskipun rata-rata tingkat kohort bernilai positif. Analisis masa depan dapat melaporkan distribusi nilai Silhouette individual, termasuk kuartil dan proporsi nilai negatif, untuk memberikan gambaran overlap yang lebih mendalam.

Davies–Bouldin Index meningkat pada sebagian besar kohort ketika k meningkat melewati dua. Pola ini menunjukkan bahwa cluster tambahan tidak secara konsisten memperbaiki rasio antara sebaran dalam cluster dan jarak antarsentroid. Terdapat perubahan kecil non-monotonik pada beberapa kohort pada k yang lebih besar, tetapi perubahan tersebut tidak membuat kandidat k yang lebih besar menjadi tidak didominasi berdasarkan aturan tiga tujuan lengkap. Pelaporan Silhouette dan DBI secara bersamaan berguna karena satu metrik saja dapat memilih partisi yang memiliki karakteristik tidak diinginkan menurut sudut pandang geometri cluster lainnya.

Pola ARI juga informatif. Pada k=2, nilai ARI berpasangan sangat tinggi. Pada k yang lebih besar, nilai tersebut secara umum menurun, yang menunjukkan sensitivitas terhadap inisialisasi yang lebih besar ketika model diminta membagi kohort menjadi lebih banyak kelompok. Hal ini tidak berarti bahwa data memiliki tepat dua populasi alami. Hal ini menunjukkan bahwa partisi dua cluster lebih mudah diperoleh kembali secara konsisten oleh algoritma dalam ruang fitur dan pengaturan optimisasi yang ditentukan. Interpretasi tersebut bersifat algoritmik dan harus dipisahkan dari teori pendidikan mengenai jumlah tingkat kemampuan siswa.

Jika dilihat secara keseluruhan, ketiga metrik menggambarkan trade-off antara pemisahan geometris, dispersi relatif, dan keterulangan inisialisasi. Seleksi Pareto tidak mereduksi dimensi tersebut menjadi satu skor berbobot. Sebaliknya, seleksi menghapus kandidat yang secara tidak ambigu lebih buruk pada ketiga kriteria. Pendekatan ini lebih baik daripada menetapkan bobot arbitrer tanpa justifikasi substantif. Meskipun demikian, hasil bergantung pada metrik yang dipilih dan arah optimasinya. Tujuan pendidikan yang berbeda—misalnya mengidentifikasi kelompok kecil yang membutuhkan dukungan intensif—dapat mendorong protokol seleksi yang berbeda, tetapi tujuan tersebut harus ditetapkan sebelum analisis dilakukan.

Metrik internal juga dipengaruhi oleh ruang fitur Euclidean yang telah distandardisasi. Jika distribusi nilai sangat menceng, mengandung outlier, atau menunjukkan hubungan nonlinier, ukuran jarak atau keluarga clustering yang berbeda mungkin lebih sesuai. Penelitian saat ini tidak menguji robust scaling, transformasi peringkat, cosine distance, atau pembobotan fitur. Oleh karena itu, temuan berlaku pada konfigurasi preprocessing dan jarak yang tepat sebagaimana dilaporkan dalam paper ini. Batasan ini harus dinyatakan secara eksplisit ketika membandingkan penelitian dengan aplikasi EDM lain yang menggunakan variabel perilaku, kategorikal, atau temporal.

REFERENSI

[1] A. Dutt, M. A. Ismail, and T. Herawan, “A systematic review on educational data mining,” IEEE Access, vol. 5, pp. 15991–16005, 2017, doi: 10.1109/ACCESS.2017.2654247.

[2] Z. Chen, G. Cen, Y. Wei, and Z. Li, “Student performance prediction approach based on educational data mining,” IEEE Access, vol. 11, pp. 131260–131272, 2023, doi: 10.1109/ACCESS.2023.3335985.

[3] M. M. Rahman, Y. Watanobe, R. U. Kiran, T. C. Thang, and I. Paik, “Impact of practical skills on academic performance: A data-driven

IEEE Access, vol. 9, pp. 139975–139993, 2021, doi: 10.1109/ACCESS.2021.3119145.

[4] E. Alhazmi and A. Sheneamer, "Early predicting of students performance in higher education," IEEE Access, vol. 11, pp. 27579–27589, 2023, doi: 10.1109/ACCESS.2023.3250702.

[5] K. Qin, X. Xie, Q. He, and G. Deng, "Early warning of student performance with integration of subjective and objective elements," IEEE Access, vol. 11, pp. 72601–72617, 2023, doi: 10.1109/ACCESS.2023.3295580.

[6] L. Vives, I. Cabezas, J. C. Vives, N. G. Reyes, J. Aquino, J. B. Cóndor, and S. F. Segura Altamirano, "Prediction of students' academic performance in the programming fundamentals course using long short-term memory neural networks," IEEE Access, vol. 12, pp. 5882–5898, 2024, doi: 10.1109/ACCESS.2024.3350169.

[7] J. Pecuchova and M. Drlik, "Enhancing the early student dropout prediction model through clustering analysis of students' digital traces," IEEE Access, vol. 12, pp. 159336–159367, 2024, doi: 10.1109/ACCESS.2024.3486762.

[8] J. Chen, S. Lau, J. Leinonen, V. Terragni, and N. Giacaman, "Detecting learning behavior in programming assignments by analyzing versioned repositories," IEEE Access, vol. 12, pp. 188828–188844, 2024, doi: 10.1109/ACCESS.2024.3514843.

[9] S. Harris and R. C. de Amorim, "An extensive empirical comparison of k-means initialization algorithms," IEEE Access, vol. 10, pp. 58752–58768, 2022, doi: 10.1109/ACCESS.2022.3179803.

[10] Andre, N. Suciati, H. Fabroyir, and E. Pardede, "Educational data mining clustering approach: Case study of undergraduate student thesis topic," IEEE Access, vol. 11, pp. 130072–130088, 2023, doi: 10.1109/ACCESS.2023.3332818.

[11] A. Mutka, F. Živković Mutka, M. Žagar, and D. Tolić, "Enhancing student retention in introductory programming courses: Leveraging advanced learning validation tools and educational data mining," IEEE Access, vol. 13, pp. 153614–153626, 2025, doi: 10.1109/ACCESS.2025.3604563.

LINK GITHUB :

https://github.com/EZZA32/UTS_FOUNDATION_TEGAR_RAHMADANI_FIRDAUS_P36.2026.00005.git